

Analiza interpretowalności modelu Action3DCNN w klasyfikacji ćwiczeń z wykorzystaniem metody Grad-CAM

Wojciech Bartoszek, Łukasz Checiak, Jarosław Kołodun, Mateusz Oracz

11 stycznia 2026

1 Wstęp i cel badania

Celem niniejszego sprawozdania jest analiza wyników modelu **Action3DCNN** przeszkolonego na zbiorze danych *Resistive Band*. Badanie skupia się na weryfikacji, czy sieć neuronowa podejmuje decyzje w oparciu o istotne biomechaniczne cechy ruchu, czy jedynie na podstawie przypadkowych korelacji. Do wizualizacji "uwagi" modelu wykorzystano technikę **Grad-CAM**.

2 Analiza wyników ilościowych

Na podstawie przebiegu procesu uczenia, model osiągnął stabilizację około 40-50 epoki.


- **Accuracy (dokładność):** Wynik na poziomie ok. **94.8%** świadczy o bardzo wysokiej zdolności generalizacji modelu dla danych szkieletowych.
- **Funkcja straty:** Krzywa *Validation Loss* ściśle podąża za krzywą treningową, co wskazuje na brak zjawiska nadmiernego dopasowania (*overfitting*) dzięki zastosowaniu Dropoutu i regularyzacji.



Rysunek 1: Przebieg funkcji straty i dokładności w czasie trenowania.

3 Macierz Kontyngencji


Po przeanalizowaniu wszystkich klas, otrzymano również mapę kontyngencji, przedstawiającą poprawność interpretacji dla poszczególnych ćwiczeń.



Rysunek 2: Macierz kontyngencji dla zadanych ćwiczeń ze zbioru.

4 Interpretacja wizualna Grad-CAM


Analiza przesłanych wizualizacji (mapy ciepła na klatkach wideo) pozwala na sformułowanie kluczowych spostrzeżeń dotyczących działania architektury 3D-CNN.




Rysunek 3: Mapa aktywacji Grad-CAM nałożona na klatki kluczowe sekwencji wideo.

4.1 Analiza sekwencji klatek (Video Analysis)


Poniżej zestawiono wyniki Grad-CAM nałożone na klatki wideo. Wyraźnie widać dynamikę "uwagi" modelu w czasie trwania ruchu.




Rysunek 4: Analiza pierwszego ćwiczenia




Rysunek 5: Analiza drugiego ćwiczenia




Rysunek 6: Analiza trzeciego ćwiczenia




Rysunek 7: Analiza czwartego ćwiczenia




Rysunek 8: Analiza piątego ćwiczenia




Rysunek 9: Analiza szóstego ćwiczenia




Rysunek 10: Analiza siódmego ćwiczenia




Rysunek 11: Analiza ósmego ćwiczenia




Rysunek 12: Analiza dziewiątego ćwiczenia




Rysunek 13: Analiza dziesiątego ćwiczenia




Rysunek 14: Analiza jedenastego ćwiczenia




Rysunek 15: Analiza dwunastego ćwiczenia




Rysunek 16: Analiza trzynastego ćwiczenia



Rysunek 17: Analiza czternastego ćwiczenia



Rysunek 18: Analiza piętnastego ćwiczenia



Rysunek 19: Analiza szesnastego ćwiczenia

5 Wnioski końcowe

Na podstawie analizy kodu oraz wyników, sformułowano trzy główne wnioski:

1. **Poprawność selekcji cech przestrzennych:** Model Grad-CAM wyraźnie wskazuje, że sieć skupia najwyższą aktywację na stawach najbardziej obciążonych w danym ćwiczeniu (np. łokcie i barki przy ćwiczeniach górnych partii). Oznacza to, że model Action3DCNN poprawnie nauczył się wyodrębniać kluczowe punkty szkieletu, ignorując punkty statyczne lub nieistotne dla danej klasy ruchu.
2. **Zależność czasowa w splotach 3D:** W odróżnieniu od klasycznych sieci 2D, wizualizacja pokazuje, że intensywność "uwagi" modelu zmienia się w fazach ruchu o największym przyspieszeniu. Potwierdza to hipotezę, że model wykorzystuje informacje o dynamice (prędkości zmian współrzędnych w czasie), a nie tylko o statycznym ułożeniu ciała, co jest kluczowe w odróżnianiu ćwiczeń o podobnej pozycji startowej.
3. **Wiarygodność modelu (Trustworthiness):** Dzięki temu, że obszary aktywacji pokrywają się z faktycznym ruchem kończyn, możemy uznać model za wiarygodny. Wysoka dokładność nie wynika z "oszustwa" (np. patrzenia na tło), lecz z poprawnej analizy trajektorii punktów kluczowych YOLO Pose.